

좌표 예측

CatBoost

LightGBM

XGBoost

PyTorch CNN

Pseudo Labeling

경진대회 상위 7%

K리그 경기 내 최종 패스 좌표 예측 AI

K리그 실제 경기 데이터로 플레이 시퀀스의 마지막 패스 도달 좌표를 예측. 4개 모델 앙상블과 Pseudo Labeling 전략으로 **Dacon 경진대회 상위 7%** 달성.

최종 순위

TOP 7%

Dacon K리그-서울시립대 경진대회

앙상블 OOF MAE

13.05m

단일 최고 13.15m → 0.10m 개선

학습 에피소드

15,428

K리그 실제 경기 데이터

앙상블 모델 수

4개

CatBoost · LGBM · XGB · CNN

프로젝트 개요

데이터 전처리

EDA

피처 엔지니어링

모델링

앙상블 전략

회고

프로젝트 개요

무엇을, 어떻게 접근했는가

단순 좌표 예측이 아닌, 경기 흐름의 시계열 패턴과 전술적 맥락을 피처로 인코딩하는 것이 핵심 과제.

01
데이터 정렬
game_id →
episode → time

02
EDA
패스 분포·오차 패턴
중앙 회귀 현상 발견

03
피처 엔지니어링
Residual 예측 설계
Gap · Lag · 통계
피처

04
모델링
4개 모델 학습
GroupKFold
Multi-See



핵심 과제 1

문제

넓은 출력 범위 (0~105m)

해결

절대 좌표 대신 **변화량(Residual)** 예측 →
분포가 0 근방에 집중되어 학습 안정성 향상



핵심 과제 2

문제

검증 설계 — 경기 단위 분리 필요

해결

GroupKFold(game_id)로 같은 경기가 학습·
검증에 동시 포함되는 데이터 누출 방지



핵심 과제 3

문제

시계열 맥락 인코딩

해결

Lag 피처(K=20) + Gap 피처 +
player_spread 통계로 **전술 패턴**을 수치화

데이터 전처리

분석 인프라 구축

K리그 실제 경기 이벤트 로그를 시계열 구조로 정렬하고, 모델이 학습하기 좋은 형태로 전처리.

학습 에피소드

15,428 개

이벤트 타입

10종 +

평가 지표

유클리드
MAE

01 시계열 정렬

02 결측치 처리

03 Residual 변환

04 GroupKFold 분리

STEP 01

시계열 정렬

game_id → episode → time 순으로 정렬하여 경기 흐름을 올바르게 반영.

같은 에피소드 내 이벤트 순서가 피쳐 생성의 기반.

EDA

데이터가 보여준 패턴

패스 도착지 분포와 모델 오차 분석에서 전략 방향을 결정하는 핵심 인사이트 발견.



패스 도착지 — x축 (공격 방향)

공격권(70m+)에 절반 이상 집중. 경기는 주로 상대 진영에서 전개.

공격권 (70m+)		55%
중원 (35~70m)		33.9%
수비권 (0~35m)		11%



패스 도착지 — y축 (폭 방향)

양쪽 사이드라인 슥림 현상. 중앙보다 측면 패스 전략 우세.

오른쪽 사이드		39.9%
왼쪽 사이드		35.4%
중앙		24.7%



오차 분포 (LGBM OOF 기준)

절반 이상이 15m 이내로 예측. 30m+ 대형 오차는 8%.

5m 이하 (정확)		20.7%
5~15m		46.3%
15~30m		25.0%
30m+ (대형 오차)		8.0%

★ 중앙 회귀 현상 발견

y좌표가 극단적으로 낮은(5 미만) 케이스에서 실제 1.68m → 예측 11.56m. 약 **10m 과대추정**. 모델이 극단값을 평균 쪽으로 끌어당기는 패턴 확인.

MAE 방향별 분해

8.37m

MAE x방향

8.41m

MAE y방향

x-y 방향 오차가 거의 동일 → 방향별 편향 없음. 2-Head 예측 구조 선택의 근거.

인사이트 → 전략 연결

공격권 집중

→ x방향 Lag 피처 강화

사이드 쏠림

→ y방향 player_spread 피처 설계

중앙 회귀 현상

→ Residual 예측 방식 선택 근거

어떤 피처가 핵심이었는가

도메인 지식(전술·포지션·흐름)을 수치로 표현하는 것이 목표. 선수 포지션 정보가 없어도 통계로 근사 가능.

★ 핵심 설계 — RESIDUAL 예측

end_x 직접 예측 → 0~105m 전체 커버 필요, 분산 큼

Residual(end_x - start_x) 예측 → 분포가 0 근방에 집중, 학습 안정성 향상. EDA에서 발견한 중앙 회귀 현상의 해결책.

GROUP 1 · 현재 상태

직전 이벤트의 공간 정보

- `last_sx / last_sy` — 직전 이벤트 좌표
- `speed_last / angle_last` — 이동 속도·방향
- `cat_type / cat_player` — 이벤트·선수 범주

GROUP 2 · GAP 피처

볼 소유권 전환 감지

- `gap_x / gap_y` — 이전 이벤트와 위치 차이
- `gap_dist` — 갭 거리 (볼 탈취 신호)
- 큰 gap = 볼 소유권 전환 가능성 → 패스 방향 크게 변화

GROUP 3 · LAG 피처 (K=20)

시계열 흐름 — 직전 20개 이벤트

- `sx/sy lag0~2` — 위치 3연속 이력
- `speed/angle lag0~2` — 속도·방향 이력
- `prev1~3_type` — 직전 이벤트 타입 패턴

GROUP 4 · 통계 피처

선수 활동 반경 근사

- `player_spread` — 선수들 간 공간 분포 (포지션 대응)
- `player_mean_x` / `player_mean_y` — 팀 무게중심
- 선수 포지션 정보 없이 통계로 근사 — 도메인 지식 활용

모델링

4개 모델 학습 전략

각 모델의 귀납 편향이 다를수록 앙상블 효과 증가. 트리 계열 3개 + 딥러닝 1개로 다양성 확보.

CatBoost

13.15m

OOF MAE · 핵심 모델

범주형 변수 직접 처리
Pseudo Labeling 적용
앙상블 가중치 ~0.58

LightGBM

13.32m

OOF MAE

$lr=0.005$ / $n_est=30K$
early_stopping 적용
앙상블 가중치 ~0.42

XGBoost

13.27m

OOF MAE

$max_depth=8$
hist 모드 속도 최적화
최종 앙상블에서 제외*

CNN + Attention

14.45m

OOF MAE

ResidualBlock + SE
AttentionPooling
최종 앙상블에서 제외*

* 4모델 전체 vs LGBM+CatBoost 2모델 앙상블 → 점수 차이 없음. 단순화 결정.

★ 검증 설계 — GroupKFold가 왜 필요한가

× 일반 KFold였다면

같은 경기(game_id)의 이벤트가 학습·검증에 동시 포함 → 데이터 누출 → OOF 성능 과대평가 → 앙상블 가중치 최적화 전체가 틀어짐

✓ GroupKFold(game_id)

경기 단위로 완전 분리 → 실제 일반화 성능 측정 → 신뢰할 수 있는 OOF MAE → 앙상블 가중치 최적화의 기반

| 앙상블 전략

성능을 끌어올린 3가지 전략

Multi-Seed 앙상블

Seeds [42, 2024, 777] 3개로 학습 후 평균

트리 기반 모델의 **랜덤성**에서 오는 분산을 줄이는 가장 쉽고 효과적인 방법. 같은 하이퍼파라미터로 시드만 바뀌어도 OOF MAE 개선.

Pseudo Labeling

Test 데이터 분포를 학습에 반영

- 01 **1차 모델로 Test 예측값 생성**
CatBoost OOF 예측 → pseudo label 생성
- 02 **Train + pseudo Test 합쳐 재학습**
`group=-1` 처리로 validation leak 방지
- 03 **OOF는 원본 train만으로 계산**
평가 공정성 유지

앙상블 가중치 최적화

최적 가중치 탐색 2가지 방법

Monte Carlo 방법

10만 회 랜덤 샘플링으로 전역 탐색

최종 가중치 결과

CatBoost  ~0.58

LightGBM  ~0.42

Scipy SLSQP 방법

제약 최적화로 정밀 탐색 (합=1, 각 $\geq$ 0)

단일 최고 **13.15m** → 앙상블 **13.05m** (0.10m 개선)

회고

솔직한 평가

● 잘 된 점

검증 설계가 전부다

GroupKFold 없이는 OOF가 낙관적 → 앙상블 가중치 최적화 전체가 틀어진다는 것을 직접 경험.

모델 수보다 다양성

4모델 전체 = LGBM+CatBoost 2모델. 모델 수를 늘리는 것보다 각 모델의 귀납 편향 다양성이 앙상블 효과를 결정.

도메인 지식이 피처를 만든다

player_spread, player_mean_x — 선수 포지션 데이터가 없어도 통계로 근사 가능. 도메인 이해가 피처 품질을 결정.

● 보완할 점

중앙 회귀 현상 미해결

$y < 5$ 케이스의 10m 과대추정을 발견했지만 별도 처리 미완.

→ 개선 극단값 케이스 별도 모델 또는 후처리 로직 추가

CNN 성능이 트리에 못 미침

ResidualBlock + SE + AttentionPooling을 적용했지만 MAE 14.45m으로 트리 계열에 뒤짐.

→ 개선 Transformer 기반 시계열 모델(TSMixer 등) 시도

Pseudo Label 노이즈

CatBoost 1차 예측을 pseudo label로 사용해 초기 오차가 누적될 가능성 존재.

→ 개선 신뢰도 높은 예측(MAE 낮은 케이스)만 선별 사용

데이터 분석 포트폴리오

K리그 경기 내 최종 패스 좌표 예측

← 이전 프로젝트

다음 프로젝트 →