

물류 · 운영 분석

LightGBM

CatBoost

PSM 인과 검증

K-Means 군집화

경진대회 상위 15%

DACON 스마트 창고 출고 지연 예측

250개 창고, 25만 건 데이터. 레이아웃이 문제라고 생각했는데 운영이었고, 중요하지 않다고 본 변수가 핵심.

분석 과정에서 결론이 세 번 바뀜. 그 인사이트로 경진대회 상위 15% 달성.

분석 창고 수

250개

4개 레이아웃 유형

지연 격차

30.8분

idle 최저 36.3분 vs
최고 5.5분

결론 수정 횟수

3회

가설 → 검증 → 수정

경진대회 성적

상위
15%

예측 모델 MAE
최적화

분석 스토리

핵심 발견

시각화

방법론

운영 전략

경진대회

한계

분석 스토리

결론이 세 번 바뀐 과정

각 단계는 이전 결론을 의심하고 검증하는 방향으로 연결.

01

EDA

02

모델링

03

경보 규칙

04

군집화

05

PSM

idle이 핵심이다

30% 임계점 발견. 배터리 소모→충전 대기→idle 감소 연쇄 구조 확인.

발견

EDA가 놓친 변수

pack_utilization 상관계수 0.105 → '관계 없음' 판단했는데 모델 중요도 1위 (14.2%).

한계 발견

임계값 방식 실패

규칙·ML 모두 Precision ~0.12 상한. 단일 시점으론 위기 예측 불가 확인.

실패→전환

취약형 102개 발견

hub_spoke 참고 67%가 취약 군집 → 레이아웃이 원인인가? 가설 형성.

가설 형성

결론이 뒤집혔다

운영 조건 통제 후 hub_spoke 효과 소멸 (p=0.783). 레이아웃이 아닌 운영이 원인.

결론 수정

처음엔 의심했다
hub_spoke 구조가 자연 원인 (+3.69분, p=0.007)

→ 수정

PSM으로 확인했다
운영이 원인 — 레이아웃 효과 없음 (p=0.783)

EDA로는 몰랐다
pack_utilization r=0.105 → '관계 없음'으로 오판

→ 수정

모델이 발견했다
비선형 U자형 패턴 — 모델 중요도 1위 (14.2%)

기대했던 것
임계값 조합으로 경보 규칙 만들 수 있을 것

→ 수정

발견한 것
Precision ~0.12 구조적 상한 — 단일 시점의 한계

핵심 발견

6가지 핵심 발견

각 발견은 독립 결과가 아니라 하나의 인과 구조로 연결.



idle 비율이 1차 방어선

30.8분

최저 36.3분 vs 최고 5.5분.
30% 아래로 떨어지면 즉각 고착. 배터리 소모→충전 대기 →idle 감소 연쇄.



숨은 병목 —
pack_utilization

r=0.105 → 1위

EDA 상관계수로는 '관계 없음'.
비선형 U자형: 저가동=처리 부족, 고가동=후처리 병목.
반례 분석과 수렴.



PSM 인과 검증

p=0.783

hub_spoke +3.69분 (p=0.007) → 운영 조건 통제 후 -0.55분(p=0.783).
레이아웃 효과 소멸. 운영 개선이 우선.



위기는 누적된다

6스냅샷 전

경보 규칙 실패 원인. 위기
6스냅샷 전부터 이미 신호가
쌓임. 단일 시점 탐지보다 누적
감지가 필요.



복합 병목 조합

3.7배

모두 정상 10.2분 → 3개 동시
나쁨 38.1분. idle만 낮아도
23.5분. idle이 1차, pack이
2차 방어선.



운영 우선순위 6유형

포장병목형★

3순위 포장병목형(27.0분)이
1순위 즉시개입형(24.6분)
보다 지연 높음. 반례 분석
없인 발견 불가능.

주요 시각화

데이터로 보는 발견들

각 차트는 독립적인 결과가 아니라 하나의 분석 흐름으로 이어짐.

시스템 구조도

idle 비율

U자형 발견

복합 병목

PSM 전후

위기 시계열

시스템 병목 인과 구조

주문 증가에서 출고 지연까지 이어지는 전체 흐름



pack 과포화 → 후처리 병목

선형 상관 0.105 → 모델 1위 (14.2%) — 숨은 병목

출고 지연 폭발

3개 동시 나뉘: 38.1분 (정상 10.2분의 3.7배)

| 방법론 선택 이유

왜 이 방법을 선택했는가

왜 GroupKFold를 선택했는가?

+

왜 상관계수 대신 모델 중요도를 봤는가?

+

왜 PSM이 필요했는가?

+

왜 반례 분석을 별도로 진행했는가?

+

왜 단일 임계값 경보가 실패했는가?

+

| 반례 분석

왜 일부 참고는 일반 패턴을 따르지 않았는가

반례 유형 1 — idle 높아도 지연이 큰 창고 (20개)

Q. idle이 충분한데 왜 지연이 큰가?

변수	일반 창고	반례 창고	배율
pack_utilization	0.436 (일반)	0.732 (반례)	1.68×
혼잡도	13.30	6.79	0.51× (오히려 낮음)
저배터리	0.213	0.085	0.40× (오히려 낮음)

결론

idle은 필요조건, pack 최적화는 충분조건 —
idle이 여유 있어도 포장 라인이 막히면
소용없음

반례 유형 2 — 혼잡 낮아도 위기가 많은 창고 (29개)

Q. 혼잡도가 낮은데 왜 위기가 자주 발생하는가?

변수	일반 창고	반례 창고	배율
pack_utilization	0.388 (일반)	0.673 (반례)	1.73×
혼잡도	4.896	4.815	0.98× (거의 동일)
저배터리	0.087	0.090	1.04× (거의 동일)

결론

단일 병목(pack)이 전체 시스템을 무력화 —
혼잡·배터리 정상이어도 pack이 막히면 위기

두 반례의 공통 원인 — pack_utilization 과포화

U자형 분석(모델 발견)과 반례 분석(예외 탐색)이 독립적인 방법으로 같은 결론에 도달.

운영 전략

운영 우선순위 매트릭스

250개 창고를 6개 운영 유형으로 분류하고 맞춤 개입 전략 제시.

★ 포장병목형(3순위) 평균 지연 27.0분 > 즉시개입형(1순위) 24.6분 — 반례 분석 없이는 발견 불가

우선순위

유형

창고 수

평균 지연

특징

즉각
조치

목표

1순위

즉시개입형

49개

24.6분

고혼잡
+
저idle경로
재배정
즉시 /
충전
스케줄
긴급
조정

idle 30% 회복

2순위

배터리위기형

23개

23.3분

저idle
+
배터리
나쁨사전
충전
스케줄
/
배터리
교체
점검

저배터리 10% 이하

3순위★

포장병목형

40개

27분

pack
고가동
(숨은
병목)포장 부하
분산 /
pack
60~80%
조정

U자형 최적 구간

4순위

혼잡관리형

29개

15.4분

idle
정상
+
고혼잡픽크타임
경로
사전
분산 /
모니터링

혼잡도 임계 이하

5순위

배터리최적화형

6개

17분

idle
정상
+
배터리
나쁨정기
충전
스케줄
최적화

low_bat 10% 관리

6순위

모니터링형

103개

13.5분

전반적
정상정기
모니터링
/
이상
징후
조기
감지

현재 상태 유지

경진대회 모델링

분석 → 예측 모델 — 상위 15%

EDA 인사이트를 바탕으로 피처를 설계하고, CatBoost·LightGBM 앙상블로 출고 지연 시간 (avg_delay_minutes_next_30m)을 예측해 상위 15% 달성.

최종 성적	평가 지표	검증 방식	총 모델 수	피처 수
상위 15%	MAE	5-Fold GroupKFold	8개 (5종 × 멀티시드)	600개+

분석 인사이트가 모델 설계에 어떻게 연결됐는가

위기는 단일 시점이 아닌 누적



lag/rolling 피처, 누적 통계, onset 이벤트 피처

pack_utilization 비선형 U자형



pack_util² 비선형 항 + 조합 상호작용 피처 명시적 추가

레이아웃보다 운영이 원인 (PSM)



layout_id는 target encoding 배경변수로만, 운영 변수 중심 설계

모델 구성

피처 엔지니어링

앙상블 전략

결과

LightGBM(MAE/Huber)과 CatBoost(MAE/RMSE) 이중 앙상블. 손실함수·깊이·시드가 모두 다른 5종 8개 모델 가중 평균.

모델명	계열	Loss	트리 수	깊이/리프	시드수	앙상블 가중치
lgbm_l1_raw_deeper	LightGBM	MAE	2,400	112	3	2
lgbm_huber_log_deeper	LightGBM	Huber	2,400	128	1	8
catboost_mae_log_depth7	CatBoost	MAE	3,000	depth=7	2	4
catboost_mae_log_depth6	CatBoost	MAE	3,000	depth=6	1	1
catboost_rmse_log_depth7	CatBoost	RMSE	3,000	depth=7	1	1

멀티시드 전략: 동일 하이퍼파라미터에 다른 시드 3개를 돌려 분산을 줄임. lgbm_l1_raw_deeper는 seed 42·123·777 앙상블 → 단일 시드 대비 OOF MAE 안정화.

솔직한 한계 진단

● 정보 규칙 Precision ~0.12 상한

단일 시점 변수만으로는 위기 예측이 구조적으로 어려움. 단일 변수 상위 10% 구간도 위기율 11% 수준이 이론적 상한.

→ 향후 LSTM/GRU로 스냅샷 시퀀스 학습 → 위기 누적 패턴 포착

● PSM 소표본 (30쌍)

매칭 쌍이 30개로 소표본이고 충전 중 비율·고장 횟수의 표준화 평균 차이(SMD)가 0.25 초과. hub_spoke 효과 없음은 잠정적 결론.

→ 향후 더 많은 참고 데이터 확보 후 재검증 필요

● 모델 수요폭증형 과소예측

300분+ 구간에서 평균 잔차 +328분. 설비 용량 자체가 수요를 따라가지 못하는 케이스는 운영 변수로 설명 불가.

→ 향후 수요폭증형 별도 모델 + 앙상블 구성

● ROI 가정 기반 추정

연간 절감 추정치(~1,855억원)는 출고 100건/시나리오, 1분=500원 등 가정에 매우 민감. 절대 금액보다 상대 우선순위가 핵심.

→ 향후 파일럿 참고 적용 후 실제 데이터로 검증 필요

데이터 분석 포트폴리오

스마트 참고 출고 지연 예측

다음 프로젝트 →